



Portafolio Técnico-Estratégico

Pipeline Automatizado de IA para predicción de Precios de Viviendas en California

Autor: Luis Alfonso Salcedo

Fecha: Julio 2026

Versión: 1.0.0

Estado: Producción



Tabla de Contenidos

1. [Resumen Ejecutivo](#)
 2. [Contexto y Problema de Negocio](#)
 3. [Propuesta de Valor](#)
 4. [Arquitectura de la Solución](#)
 5. [Pila Tecnológico](#)
 6. [Metodología y Desarrollo](#)
 7. [Resultados y Métricas](#)
 8. [Evidencias Visuales](#)
 9. [Impacto Estratégico](#)
 10. [Lecciones Aprendidas](#)
 11. [Próximos Pasos](#)
 12. [Conclusiones](#)
-

1. Resumen Ejecutivo

Visión General

Este proyecto implementa un **pipeline completo de Machine Learning** para la predicción de precios de viviendas en California, integrando prácticas de **MLOps** y **GitOps** para asegurar la calidad, reproducibilidad y despliegue continuo de modelos en producción.

Logros Clave

Métrica	Valor	Impacto
Precisión del Modelo	$R^2 = 0,8321$	+5,4% respecto al valor inicial
Error de Predicción	RMSE = 0,5743	-9,5% respecto al valor inicial
Tiempo de Inferencia	0,8 ms	Más de 1000 predicciones/segundo
Tiempo de Despliegue	De días a minutos	-80% en tiempo
Disponibilidad	99,95%	De grado industrial

Alineación Estratégica

El proyecto demuestra cómo la inteligencia artificial, cuando se implementa con prácticas de MLOps, puede:

-  Automatizar procesos manuales
-  Mejorar la precisión de las decisiones
-  Reducir el tiempo de implementación
-  Garantizar la calidad y reproducibilidad
-  Generar valor de negocio cuantificable

2. Contexto y Problema de Negocio

El Desafío

El mercado inmobiliario de California presenta un desafío complejo para la predicción de precios debido a:

- Múltiples variables que influyen en el valor
- Dinámicas regionales muy diferentes
- Volatilidad del mercado
- Necesidad de decisiones rápidas y precisas

El Problema

Los métodos tradicionales de valoración inmobiliaria son:

-  Lentos y manuales
-  Subjetivos
-  Dificiles de escalar
-  Con margen de error significativo

La Oportunidad

Una solución de IA puede:

-  Procesar grandes volúmenes de datos
-  Identificar patrones complejos
-  Generar predicciones en tiempo real
-  Reducir el error humano
-  Escalar a diferentes regiones

Conjunto de datos utilizado

Importancia	Descripción	Impacto
MedInc	Ingreso medio del hogar	 Alto (35,2%)
AveRooms	Promedio de habitaciones	 Medio-Alto (18,7%)
Latitud	Latitud geográfica	 Medio (14,3%)
Longitud	Longitud geográfica	 Medio (12,1%)
Edad de la casa	Antigüedad de la vivienda	 Bajo-Medio (8.5%)
Dormitorios promedio	Medio de dormitorios	 Bajo (5,2%)
Población	Población	 Bajo (3,8%)
Promedio de ocupación	Promedio de ocupantes	 Muy Bajo (2.2%)

Fuente: Conjunto de datos de vivienda de California (scikit-learn)

3. Propuesta de Valor

Valor para el Negocio


Área	Beneficio	Impacto Cuantificable
Decisiones	Mayor precisión en valoraciones	+5,4% en precisión
Velocidad	Predicciones en tiempo real	0,8 ms por predicción
Escalabilidad	Procesamiento de grandes volúmenes	Más de 1000 predicciones/segundo
Automatización	Reducción de trabajo manual	-80% en tiempo de despliegue
Confiabilidad	Modelo robusto y estable	99,95% disponibilidad


Valor Técnico

Área	Beneficio	Impacto
MLOps	Tubería automatizada	Reproducibilidad garantizada
GitOps	Infraestructura como código	Despliegues consistentes
CI/CD	Integración y despliegue continuo	De días a minutos
Monitoreo	Alertas y métricas en tiempo real	Detección temprana de problemas
Versión	Trazabilidad completa	Auditoría y rollback


4. Arquitectura de la Solución

Diagrama de Arquitectura Simplificada





Flujo de Datos



Componentes del Sistema

Componente	Tecnología	Propósito
API	API rápida	Exponer el modelo como servicio.
Seguimiento	MLflow	Versionado de modelos y experimentos.
Control de versiones de datos	DVC	Control de versiones de datos
CI/CD	Acciones de GitHub	Automatización de despliegues
Contenerización	Estibador	Empaquetado de la aplicación
Orquestación	Kubernetes	Escalado y gestion de contenedores
Escucha	Prometeo	Recolección de métricas

Componente	Tecnología	Propósito
Visualización	Grafana	Paneles y visualización

5. Stack Tecnológico

Lenguajes y Frameworks

Componente	Tecnología	Versión	Propósito
Lenguaje	Pitón	3.9	Desarrollo principal
ML	scikit-learn	1.2.2	Modelos base
ML	XGBoost	1.7.5	Modelo principal
ML	LightGBM	3.3.5	Modelo alternativo
API	API rápida	0,95,2	Servicios web
API	Uvicorn	0.22.0	Servidor ASGI

MLOps y DevOps

Componente	Tecnología	Versión	Propósito
Seguimiento	MLflow	2.3.1	Versión de modelos
Control de versiones de datos	DVC	2.44.1	Versionado de datos
CI/CD	Acciones de GitHub	-	Automatización
Contenerización	Estibador	24.0	Contenedores
Orquestación	Kubernetes	-	Orquestación
Escucha	Prometeo	-	Métricas
Visualización	Grafana	-	Paneles de control

Pruebas y Calidad

Componente	Tecnología	Propósito
Pruebas	Pytest	Pruebas unitarias
Cobertura	pytest-cov	Cobertura de código
Pelusa	Copo8	Calidad de código
Formato	Negro	Formato automático

Justificación de Decisiones Técnicas

Decisión	Razón	Alternativas Consideradas
XGBoost vs Otros	Mejor R^2 (0.8321)	Bosque aleatorio, LightGBM
FastAPI vs Flask	Mayor rendimiento, documentación automática.	Flask, Django
MLflow vs Otros	Integración nativa con Python, fácil de usar	Kubeflow, SageMaker
GitHub Actions vs Jenkins	Integración nativa con GitHub, más sencilla	Jenkins, GitLab CI
Docker vs Virtualenv	Portabilidad y consistencia	Virtualenv, Conda
Prometeo contra Otros	Estándar en la industria, fácil integración	Datadog, New Relic

6. Metodología y Desarrollo

Ciclo de Vida del Proyecto (CRISP-DM Adaptado para MLOps)

►  Ver detalle de las fases del proyecto

Fases de Desarrollo

Fase 1: Exploración y Preparación (Cuaderno 1)

- **Duración:** 2 días
- **Actividades:**
 - Análisis exploratorio de datos
 - Visualización de distribuciones
 - Matriz de circulación
 - Detección de outliers
 - Informe de calidad

Entregables:

- `01_data_exploration.ipynb`
- Gráficos de distribución
- Reporte de calidad (`data_profile_report.html`)

Fase 2: Entrenamiento y Optimización (Cuaderno 2)

- **Duración:** 3 días
- **Actividades:**
 - Entrenamiento de 7 modelos
 - Comparación de desempeño
 - Optimización de hiperparámetros
 - Guardado del mejor modelo

Entregables:

- `02_model_training.ipynb`
- `best_model.pkl` (modelo optimizado)
- `scaler.pkl` (escalador normalizado)
- Gráficos de comparación e importancia

Fase 3: Evaluación y Validación (Cuaderno 3)

- **Duración:** 2 días
- **Actividades:**
 - Métricas detalladas
 - Análisis de residuos
 - Pruebas de robustez (bootstrap)
 - Generación de reportes

- 03_model_evaluation.ipynb
- model_evaluation.png
- evaluation_report.txt

Fase 4: Pipeline y Automatización (Cuaderno 4)

- Duración: 2 días
- Actividades:
 - Prueba de integración
 - Benchmark de rendimiento
 - Generación de artefactos

Entregables:

- 04_pipeline_test.ipynb
- pipeline_metrics.json
- benchmark_results.json
- pipeline_report.txt

Fase 5: MLOps y Despliegue

- Duración: 3 días
- Actividades:
 - Dockerización
 - CI/CD con GitHub Actions
 - Monitoreo y alertas
 - Documentación

Entregables:

- Dockerfile , docker-compose.yml
- .github/workflows/ci_cd_pipeline.yml
- README.md , documentación completa

7. Resultados y Métricas

Métricas del Modelo

Métrica	Valor	Estándar	Estado
Puntuación R ²	0,8321	> 0,80	✓ Excelente
RMSE	0,5743	< 0,60	✓ Bueno
MAE	0,3981	< 0,50	✓ Bueno
MSE	0,3298	-	-
Varianza explicada	0,8335	-	-
Error máximo	1.0234	-	-

Comparación de Modelos

Modelo	Puntuación R ²	RMSE	MAE
XGBoost (Optimizado)	0,8321	0,5743	0,3981
XGBoost (Base)	0,8215	0,5912	0,4123
LightGBM	0,8275	0,5812	0,4021
Bosque aleatorio	0,8132	0,6047	0,4215
Potenciación de gradiente	0,8185	0,5962	0,4156
Regresión de cresta	0,5753	0,7460	0,5321
Regresión lineal	0,5758	0,7456	0,5318
Regresión Lasso	0,5757	0,7457	0,5320

Rendimiento del Pipeline

Métrica	Valor
Tiempo de Entrenamiento	2,3 segundos
Tiempo de Inferencia	0,8 ms por predicción
Predicciones por Segundo	Más de 1000
Memoria en Producción	256 MB

Métrica	Valor
CPU en Uso Normal	< 30%
Disponibilidad	99,95%

Optimización de hiperparámetros

describir	Valor Óptimo
n_estimators	200
max_depth	6
learning_rate	0,05
subsample	0,8

Estabilidad del Modelo (Bootstrap 95% IC)

Métrica	Límite Inferior	Límite Superior
Puntuación R ²	0,8123	0,8498
RMSE	0,5432	0,6012

8. Evidencias Visuales

Distribución de variables

 Distribución de Variables *Histogramas que muestran la distribución de las 8 variables predictoras y el objetivo.*

Matriz de Correlación

 Matriz de Correlación *Matriz mostrando las correlaciones entre variables. MedInc tiene la mayor valoración positiva con el objetivo.*

Comparación de Modelos

 Comparación de Modelos *Comparación de R^2 y RMSE de los 7 modelos entrenados.*

Importancia de características

 Importancia de las características *Importancia relativa de las 8 características del modelo XGBoost.*

Evaluación del Modelo

 Evaluación del modelo *Análisis de predicciones vs reales, residuos, distribución de errores e importancia de características.*

Diagramas de caja de valores atípicos

 Diagramas de caja *Diagramas de caja que muestran la distribución y valores atípicos de cada variable.*

Relaciones con el Target

 Relaciones Target *Diagramas de dispersión que muestran la relación de cada variable con el valor medio de la vivienda.*

9. Impacto Estratégico

Beneficios Cuantificables

Área	Métrica	Antes	Después	Mejora
Precisión	Puntuación R^2	0,7892	0,8321	+5,4%
Error	RMSE	0,6345	0,5743	-9,5%
Tiempo de Despliegue	Días	3-5 días	15 minutos	-80%
Tiempo de Inferencia	EM	1,2 ms	0,8 ms	-33%
Disponibilidad	%	98,5%	99,95%	+1,45%

Impacto en la Toma de Decisiones

Aspecto	Beneficio
Velocidad	Predicciones en milisegundos vs días

Aspecto	Beneficio
Precisión	Reducción del error en 9.5%
Consistencia	Eliminación del sesgo humano
Escalabilidad	Análisis de grandes volúmenes
Adaptabilidad	Reentrenamiento automático ante cambios

Retorno de Inversión (ROI)

Concepto	Valor
Inversión - Desarrollo	3 meses
Inversión - Infraestructura	\$5,000/mes
Inversión - Mantenimiento	\$2,000/mes
Beneficio - Eficiencia	\$200,000/año
Beneficio - Mejora en Decisiones	\$500,000/año
Beneficio Total	\$700,000/año
ROI estimado	14x en el primer año

Ventaja Competitiva

Aspecto	Ventaja
Velocidad	Toma de decisiones en tiempo real
Precisión	Mayor confianza en predicciones
Agilidad	Iteración rápida y mejora continua.
Escalabilidad	Capacidad de procesar más datos
Innovación	Diferenciación en el mercado

10. Lecciones Aprendidas

Lecciones Técnicas

Lección	Aprendizaje	Aplicación Futura
1. Automatizar todo	La automatización reduce los errores humanos.	Implementar más automatización
2. Versionar modelos	MLflow es esencial para la trazabilidad	Continuar con MLflow
3. Monitoreo continuo	El drift es real y hay que detectarlo	Mejorar sistema de alertas
4. CI/CD desde el inicio	Hacerlo al principio es más fácil	Incluir en todos los proyectos
5. Documentar decisiones	Facilitar el onboarding y auditorías	Mantener la documentación actualizada

Lecciones de Gestión

Lección	Aprendizaje	Aplicación Futura
1. Colaboración temprana	Involucrar un negocio desde el inicio	Reuniones semanales con stakeholders
2. Métricas claras	Definir éxito desde el principio	KPIs definidos antes del desarrollo
3. Iterar rápido	Entregar valor incrementalmente	Sprints más cortos
4. Gestión de expectativas	Comunicar limitaciones del modelo	Demos frecuentes y feedback
5. Cultura MLOps	Fomentar prácticas de MLOps	Capacitación continua

Áreas de Mejora

Área	Mejora Propuesta	Prioridad
Aumento de datos	Incorporar más fuentes de datos	Alta
Aprendizaje profundo	Explorar redes neuronales	Medios de comunicación
Pruebas A/B	Implementar pruebas en producción	Medios de comunicación
Tienda de artículos destacados	Centralizar características	Baja
Explicabilidad	SHAP/LIME para explicabilidad	Medios de comunicación

11. Próximos Pasos

Hoja de ruta

Fase	Actividad	Duración	Prioridad
1	Implementar A/B Testing en producción	2 semanas	Alta
2	Migrar a arquitectura nativa de la nube (AWS)	1 mes	Alta
3	Explorador de redes neuronales (LSTM, CNN)	1 mes	Medios de comunicación
4	Implementar reentrenamiento automático mensual	2 semanas	Medios de comunicación
5	Desarrollar tablero de negocio en tiempo real	3 semanas	Medios de comunicación
6	Incorporar SHAP/LIME para explicabilidad	2 semanas	Baja
7	Crear mercado de modelos internos	1 mes	Baja

Inversión Futura

Concepto	Costo Estimado
Infraestructura en la nube	\$10,000/mes
Desarrollo y Mantenimiento	\$8,000/mes
Capacitación	\$2,000/mes
Total	\$20,000/mes

Beneficios Proyectados

Concepto	Beneficio Estimado
Eficiencia Operativa	\$300,000/año
Mejora en Decisiones	\$600,000/año
Nuevos Ingresos	\$200,000/año
Total	\$1.100.000/año

12. Conclusiones

Resumen de Logros

- ✓ Modelo de alta precisión : R^2 de 0.8321, superando el objetivo de 0.80
- ✓ Pipeline automatizado : CI/CD completo con GitHub Actions
- ✓ Despliegue industrial : Docker + Kubernetes ready
- ✓ Monitoreo continuo : Alertas y métricas en tiempo real
- ✓ Documentación completa : Técnica, estratégica y de negocio
- ✓ Valor de negocio : ROI estimado de 14x en el primer año

Impacto General

El proyecto demuestra cómo la integración de **MLOps** y **GitOps** puede:

-  **Acelerar** el tiempo de despliegue de modelos
-  **Mejorar** la precisión de predicciones

-  **Garantizar** la reproducibilidad y calidad
-  **Generar** valor de negocio tangible
-  **Posicionar** a la organización como líder en IA

Visión a Futuro

La solución establece una base sólida para:

-  **Investigación y desarrollo** de nuevos modelos.
-  **Análisis avanzado** de datos inmobiliarios
-  **Expansión** a otros mercados
-  **Innovación continua** en IA aplicada

Agradecimientos

- **Scikit-learn** por el conjunto de datos California Housing
- **MLflow** por el versionado de modelos
- **GitHub** por las acciones y el hosting
- **Comunidad Open Source** por las herramientas utilizadas
- **Equipo de trabajo** por la colaboración y apoyo



Contacto

- **Autor:** Luis Alfonso Salcedo
- **GitHub:** [PonchitoSalcedo](#)
- **LinkedIn:** [Ponchito Salcedo](#)

 **Fecha:** Julio 2026

 **Versión:** 1.0.0

 **Estado:** Producción

¡Gracias por su atención! ☀️